A pergunta do trabalho: *Quanto a mortalidade de 60 a 69 anos na Baixada Santista depende de onde (município) e de quando (ano)?*

Ivan, Gustavo e Jorge

27 de outubro de 2026

Fatec Baixada Santista – Rubens Lara
Tecnologia em Ciência de Dados | Teoria do Aprendizado Estatístico | Prof. Dr. João Paulo Ferreira de Mello
Ivan – RA 0051352421038 | Gustavo – RA 0051352511009 | Jorge – RA 0051352511005

Repositório: `proj_ivan_gustavo_jorge_IPDM`

1 Introdução

O monitoramento da mortalidade na faixa etária de 60 a 69 anos é um instrumento decisivo para o planejamento de políticas públicas de saúde, especialmente no dimensionamento da atenção básica e da rede hospitalar de média e alta complexidade. Na Região Metropolitana da Baixada Santista, identificar se os óbitos nessa faixa respondem sobretudo a diferenças estruturais permanentes entre municípios, a choques temporais ou a flutuações de indicadores socioeconômicos permite alocar recursos regionais com maior precisão.

Seguindo o arcabouço da Teoria do Aprendizado Estatístico (James et al., 2021), este documento apresenta o banco de dados do trabalho, formula duas perguntas candidatas — uma de regressão focada em inferência estrutural (P_1) e outra de classificação preditiva (P_2) — e defende a escolha de P_1 por meio de diagnósticos formais e validação cruzada. Conforme destacam Bruce et al. (2020), a definição rigorosa da métrica de erro e da linha de base precede a seleção de qualquer modelo parametrizado ou flexível.

2 O banco de dados e o problema

Os dados provêm do Índice Paulista de Desenvolvimento Municipal (IPDM), compilado pela Fundação Seade (2024). A unidade amostral é o par **município-ano**: o recorte abrange os 9 municípios da Região Metropolitana da Baixada Santista (Bertioga, Cubatão, Guarujá, Itanhaém, Mongaguá, Peruíbe, Praia Grande, Santos e São Vicente) observados em 6 edições bienais (2014, 2016, 2018, 2020, 2022 e 2024), totalizando $n = 54$ observações em um painel perfeitamente balanceado.

A variável resposta de interesse é `mortalidade_60_69` (Y), que registra a taxa de mortalidade de residentes de 60 a 69 anos (óbitos por mil habitantes nessa faixa etária). O *problema de decisão* pertence às secretarias municipais e à gestão regional de saúde da Baixada Santista: decidir quais municípios demandam priorização estrutural permanente

na prevenção ao óbito precoce de idosos e separar esse efeito estrutural local de choques epidemiológicos globais (como a pandemia de COVID-19).

3 As duas perguntas candidatas

Ao longo das etapas exploratórias do projeto (Atividades 03 a 08), constatou-se que regredir a mortalidade exclusivamente contra indicadores sociais agregados sem controlar pelo município e pelo ano resultava em modelos incapazes de superar a média amostral. Para confrontar formalmente o paradigma de efeitos estruturais contra o de predição puramente socioeconômica, formulamos as duas perguntas candidatas detalhadas na Tabela 1.

Tabela 1: Ficha das duas perguntas candidatas

Campo	**Pergunta 1 (escolhida)**	**Pergunta 2 (concorrente)**
1. Pergunta	Quanto a mortalidade de 60 a 69 anos varia com *onde* (município) e *quando* (ano) — e quais municípios ficam acima do esperado para o seu ano?	Só com indicadores sociais, é possível antecipar quais município-anos terão mortalidade de 60 a 69 anos acima da mediana?
2. Resposta Y	`mortalidade_60_69`, quantitativa contínua (mortes por mil hab.)	$\mathbf{1}\{$`mortalidade_60_69` $>$ $\text{mediana}_{\text{treino}}\}$, binária (0/1)
3. Preditores X	`municipio` (9 níveis) e `ano` como fator (6 níveis); $p = 13$ *dummies*	`riqueza`, `escolaridade` e `distorcao_em` ($p = 3$)
4. Tipo	supervisionado; regressão; **inferência**	supervisionado; classificação; **predição**
5. Métrica	RMSE em mortes/mil hab. (apoio: MAE) em CV(5)	AUC (apoio: acurácia) em CV(5)
6. Linha de base	média do treino: RMSE = 3,84 (MAE = 2,97)	classe majoritária: acurácia = 42,4%; AUC = 0,500
7. Dono do problema	Secretarias de saúde da Baixada: priorizar recursos na rede de atenção ao idoso	Gestão regional: sinalizar risco via indicadores sociais antes do fechamento de óbitos

Fonte: Elaborada pelos autores.

Na Pergunta 1, o modelo aditivo de efeitos fixos de painel assume a forma estrutural:

$$y_{it} = \mu + \alpha_i + \gamma_t + \varepsilon_{it}, \qquad i = 1, \ldots, 9 \text{ (municípios)}, \quad t = 1, \ldots, 6 \text{ (anos)}, \tag{1}$$

onde α_i mede o desvio estrutural do município i e γ_t captura o choque comum do biênio t (James et al., 2021).

4 Defesa da pergunta e validação cruzada

A Tabela 2 sintetiza as quatro verificações diagnósticas realizadas sobre o banco.

Vazamento. O diagnóstico de correlação aponta `longevidade` ($|r| = 0{,}490$) e `ipdm` ($|r| = 0{,}398$) como as variáveis mais correlacionadas com Y. Embora os valores estejam longe de 1,00 e não disparem um alarme puramente numérico, a auditoria do dicionário metodológico da Fundação Seade revela um **vazamento conceitual por circularidade**: o indicador sintético de `longevidade` é calculado diretamente a partir da taxa de mortalidade de 60 a 69 anos, e o `ipdm` é a média aritmética de riqueza, longevidade e escolaridade. Portanto, ambas foram banidas de P_1 e P_2. Entre os preditores socioeconômicos legítimos, a maior correlação linear com Y é a de `riqueza` ($|r| = 0{,}393$).

Tabela 2: Diagnóstico do banco de dados

Verificação	**Resultado**
Tamanho ($n \times p$)	$n = 54$; P_1: $p = 13$ *dummies* ($n/p = 4{,}2$) | P_2: $p = 3$ ($n/p = 18{,}0$)
Linha de base em CV(5)	P_1: RMSE = 3,84 (DP = 0,93) | P_2: acurácia = 42,4%, AUC = 0,500
Maior correlação com Y	Bruta: `longevidade` (0,490) e `ipdm` (0,398); sem vazamento: `riqueza` (0,393)
Balanço (P_2, base cheia)	27 alta (50,0%) vs. 27 baixa (50,0%); corte na mediana global = 19,40
Valores faltantes	0 (nenhuma coluna possui valores ausentes)

Fonte: Elaborada pelos autores.

Tamanho, balanço e dependência. Com $n = 54$ e $p = 13$ na Pergunta 1, a razão $n/p = 4{,}2$ exige cautela, mas o desenho ortogonal do painel garante exatamente 6 observações por município e 9 por ano. Na Pergunta 2, o corte pela mediana é reestimado **estritamente dentro de cada dobra de treino** para evitar vazamento de informação do conjunto de validação. Além disso, como cada município se repete 6 vezes, a validação cruzada aleatória é otimista para P_2 caso o objetivo fosse extrapolar para um município externo à Baixada.

Tabela 3: Validação cruzada ($k = 5$): média entre dobras (desvio-padrão)

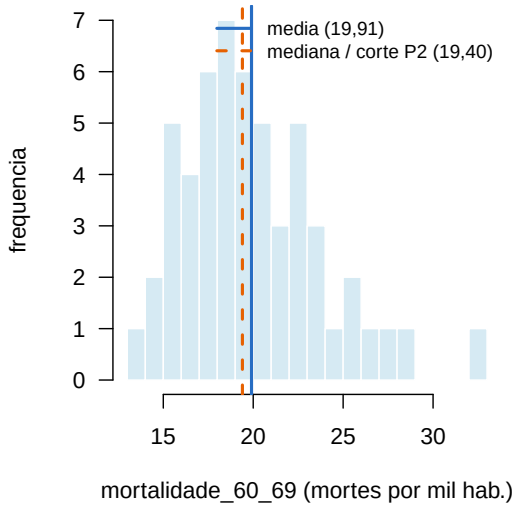
Pergunta	**Modelo avaliado**	**Métrica principal**	**Métrica de apoio**	**Redução erro**
P_1 (RMSE, MAE)	Linha de base: média do treino	3,84 (0,93)	MAE = 2,97	0,0%
	`lm`: `municipio + factor(ano)`	**2,20** (0,25)	MAE = **1,71**	**42,6**%
	`lm`: `municipio + factor(ano) + 3 sociais`	2,44 (0,44)	MAE = 1,88	36,4%
P_2 (AUC, Acc)	Linha de base: classe mais comum	0,500 (0,000)	Acc = 42,4%	0,0%
	`glm` logístico (3 ind. sociais)	0,679 (0,206)	Acc = 64,4%	38,2%
	`lm` da P_1 cortado na mediana do treino	**0,890** (0,107)	Acc = **86,7**%	**77,0**%

Fonte: Elaborada pelos autores. Mesmas dobras (`seed = 1`) em todos os modelos; base e mediana reestimadas em cada dobra.

Escolha pelos números e prova de dominância. Conforme demonstra a Tabela 3, a Pergunta 1 reduz o RMSE fora da amostra de 3,84 para **2,20** mortes por mil habitantes (eliminando **42,6**% do erro da linha de base), enquanto a logística socioeconômica da Pergunta 2 elimina 38,2% do erro de classificação (AUC = 0,679). O argumento definitivo está na última linha da Tabela 3: quando dicotomizamos a predição contínua da Pergunta 1 na mediana do treino de cada dobra para responder à Pergunta 2, obtemos AUC = **0,890** e acurácia de **86,7**%, batendo com ampla margem o próprio modelo logístico da Pergunta 2 (0,679). Em suma: a Pergunta 1 contém a resposta da Pergunta 2 com desempenho superior, além de entregar a magnitude em óbitos por mil habitantes.

Resultados substantivos e veredito. O ajuste da Pergunta 1 revela que, em torno da média regional (19,91 mortes/mil hab.), os municípios estruturalmente mais vulneráveis são Mongaguá (+4,02) e Itanhaém (+2,36), ao passo que Santos apresenta o menor patamar (−4,65). No eixo temporal, o biênio pandêmico de 2022 produziu um choque positivo severo de +4,75 mortes/mil hab., seguido de retração em 2024 (−3,48). Somar os três indicadores sociais contínuos ao modelo fixo eleva o RMSE para 2,44 devido ao excesso de parâmetros colineares com o efeito municipal em $n = 54$. A pergunta escolhida se sustenta e permanece **provisória** até a revisão após a Aula 12, quando suavizadores não-paramétricos (GAM) e árvores/*ensembles* permitirão testar não-linearidades e interações município × ano.

Figura 1: Distribuição da taxa de mortalidade de 60 a 69 anos na Baixada Santista (2014–2024)



Fonte: Elaborada pelos autores.

Referências

Peter Bruce, Andrew Bruce, and Peter Gedeck. *Practical Statistics for Data Scientists*. O'Reilly Media, Sebastopol, 2 edition, 2020.

Fundação Seade. Índice Paulista de Desenvolvimento Municipal (IPDM) — Região Metropolitana da Baixada Santista (2014–2024). Portal de Estatísticas do Estado de São Paulo (SEADE), 2024. Disponível em: `https://ipdm.seade.gov.br/`.

Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning: with Applications in R*. Springer, New York, 2 edition, 2021.