

A pergunta do trabalho: *Quanto a mortalidade de 60 a 69 anos na Baixada Santista depende de onde (município) e de quando (ano)?*

Ivan, Gustavo e Jorge

9 de outubro de 2026

Fatec Baixada Santista – Rubens Lara
Tecnologia em Ciência de Dados | Teoria do Aprendizado Estatístico | Prof. Dr. João
Paulo Ferreira de Mello

Ivan – RA 1999000
Gustavo – RA 2004000
Jorge – RA 2006000

Repositório: `proj_ivan_gustavo_jorge_IPDM`

1 Introdução

O monitoramento da mortalidade é essencial para o planejamento de políticas públicas de saúde, sobretudo para a população idosa (60 a 69 anos), que demanda maior atenção e recursos do sistema de saúde. Compreender como essa mortalidade varia na Baixada Santista pode ajudar na alocação mais eficiente de recursos e na identificação de municípios que necessitam de intervenções prioritárias. O presente texto apresenta o banco de dados escolhido, formula a pergunta do trabalho e mostra que os dados têm condição de respondê-la, auxiliando as secretarias de saúde da região.

Referências entram pela NBR 10520. Com o autor ao fim da frase, o formato sai entre parênteses James et al. (2021); com o autor no corpo do texto, use `\citeonline` — segundo Bruce and Bruce (2019), a escolha da métrica vem antes da escolha do modelo.

2 O banco de dados e o problema

O banco de dados utilizado é o Índice Paulista de Desempenho Municipal (IPDM) da Baixada Santista, mantido pela Fundação Seade Fundação Sistema Estadual de Análise de Dados (2023). Cada linha representa o registro de um município da Baixada Santista em um determinado ano. As colunas principais incluem indicadores sociais (como riqueza e escolaridade) e a taxa de mortalidade na faixa de 60 a 69 anos. O conjunto usado tem $n = 54$ observações e $p = 13$ preditores candidatos.

A escolha deste banco se justifica pela relevância e disponibilidade de dados consistentes sobre as condições de vida e saúde na região. O *problema* a ser resolvido envolve a decisão, por parte das secretarias de saúde da Baixada Santista, de onde priorizar a atenção e os recursos voltados à população de 60 a 69 anos. Uma resposta baseada em

dados permitiria que a gestão regional sinalizasse e priorizasse áreas de maior risco com mais segurança do que a abordagem atual.

3 A pergunta

A pergunta central do trabalho é: *Quanto a mortalidade de 60 a 69 anos varia com onde (município) e quando (ano) — e quais municípios ficam acima do esperado para o seu ano?* A Tabela 1 detalha os sete campos que a definem.

Tabela 1: Ficha da pergunta

Campo	Preenchimento
1. A pergunta, em uma frase	<i>Quanto a mortalidade de 60 a 69 anos varia com onde (município) e quando (ano) — e quais municípios ficam acima do esperado para o seu ano?</i>
2. Resposta Y : coluna, tipo, unidade	mortalidade_60_69 — quantitativa — <i>mortes por mil hab.</i>
3. Preditores X : quais e quantos	município (9 níveis) e ano como categoria (6 níveis) ($p = 13$)
4. Tipo: as três decisões	supervisionado; regressão; <i>inferência</i>
5. Métrica	RMSE, na unidade de Y em validação cruzada (5 dobras)
6. Linha de base a bater	RMSE = 3,85 (chutar sempre a média)
7. Dono do problema	<i>Secretarias de saúde da Baixada: decidir onde priorizar a atenção à população de 60 a 69 anos</i>

Fonte: Elaborada pelos autores.

A abordagem escolhida é de inferência, pois o objetivo principal é entender e explicar o comportamento da variável de resposta com base nos preditores, identificando desvios e padrões estruturais. Conforme evidenciado no campo 7, a resposta pode influenciar diretamente a tomada de decisão das secretarias de saúde da Baixada Santista na priorização de recursos.

4 Defesa da pergunta

A Tabela 2 reúne as quatro verificações feitas sobre o banco.

Tabela 2: Diagnóstico do banco

Verificação	Resultado
Tamanho ($n \times p$)	54×13
Linha de base	RMSE = 3,85 (chutar sempre a média)
Maior correlação com Y	longevidade : 0,490
Balanco das classes	não se aplica (resposta quantitativa)
Valores faltantes	nenhum

Fonte: Elaborada pelos autores.

Vazamento. A linha “maior correlação” da Tabela 2 aponta o preditor **longevidade** como o mais parecido com a resposta. Como o dicionário de variáveis mostra que **longevidade**


já contém a taxa de mortalidade de 60–69 anos e que o `ipdm` contém `longevidade`, isso denuncia variáveis que já contém a resposta. Logo, optamos por mantê-las fora da formulação desta pergunta para evitar vazamento de dados.

Tamanho. São 54 observações para 13 preditores. Com a relação de $n/p \approx 4,2$, o cenário é apertado, mas viável: cada categoria aparece ao menos 6 vezes e o erro do modelo é medido fora da amostra (validação cruzada).

Balanco e faltantes. O banco não possui valores faltantes (nenhum), não sendo necessário aplicar técnicas de imputação. Como a resposta é quantitativa, o balanço de classes não se aplica (resposta quantitativa).

A Figura 1 mostra a distribuição da resposta.

Figura 1: Distribuição da resposta `mortalidade_60_69`



Fonte: Elaborada pelos autores.

Veredito. A pergunta se sustenta. O modelo base atinge um RMSE de 3,84, enquanto a inclusão dos preditores `município` e `ano` reduz o erro para um RMSE de 2,20 em validação cruzada, removendo 42,6% do erro da linha de base.

A pergunta é **provisória**: será revista depois da Aula 12, pois a aplicação de árvores, *ensembles* e técnicas de regularização pode refinar a abordagem e permitir testar interações mais complexas.

Referências

Peter Bruce and Andrew Bruce. *Practical Statistics for Data Scientists*. O'Reilly Media, Sebastopol, 2 edition, 2019.

Fundação Sistema Estadual de Análise de Dados. índice paulista de desenvolvimento municipal (`ipdm`). Portal SEADE, 2023. Acesso em: 9 de outubro de 2026.

Gareth James, Daniela Witten, Trevor Hastie, and Robert Tibshirani. *An Introduction to Statistical Learning: with Applications in R*. Springer, New York, 2 edition, 2021.