Fatec
Baixada Santista
Rubens Lara

Aula 12 — Agrupamento e componentes principais

K-médias; agrupamento hierárquico; número de grupos; PCA

Prof. Dr. João Paulo Ferreira de Mello

26 de outubro de 2026

Ciências de Dados
Fatec Rubens Lara – Baixada Santista

O que vamos ver hoje

- **De onde viemos:** onze aulas com uma **resposta** Y — o preço, o imóvel caro ou não. Todo modelo foi ajustado para prever Y e julgado contra o Y verdadeiro, na validação cruzada.
- **O novo:** e quando não há Y? É o **aprendizado não supervisionado**: achar **grupos** de observações parecidas (**agrupamento**: K-médias e hierárquico) e **direções** que resumem muitas colunas em poucas (**componentes principais**, ou PCA, do inglês *principal component analysis*).
- **Para onde vai:** esta é a última aula de conteúdo. As próximas sessões são dos **trabalhos** — e o que vemos hoje entra neles como exploração do banco de cada grupo.

O fio da aula: um **cadastro de 300 imóveis** que a imobiliária comprou, com seis características e *sem* o tipo de cada imóvel.

Sem resposta: o que dá para aprender?

Supervisionado (Aulas 4 a 11): os dados são pares $(\mathbf{x}_i, y_i)$; o objetivo é prever ou explicar Y; o erro se mede contra o Y verdadeiro.

Não supervisionado (hoje): só os $\mathbf{x}_i$. O objetivo é achar estrutura nas próprias colunas:

- há *tipos* de imóvel? (agrupamento)
- seis colunas medem seis coisas? (PCA)

Sem Y, não há erro de validação para conferir: o resultado se julga pela coerência e pela utilidade.

O cadastro, com $n = 300$ imóveis e $p = 6$ colunas:

```
head(cad, 4)

#>   area quartos banheiros vagas dist idade
#> 1   91       3         1     1  3.6    11
#> 2   69       2         2     1  2.2    41
#> 3  143       4         3     2  0.7    22
#> 4  125       4         2     2  0.2    23
```

Área (m²), quartos, banheiros, vagas, distância até a praia (km) e idade (anos). É simulado, como sempre: **sabemos** que há três perfis — 110 imóveis na orla, 100 no centro e 90 afastados. O R não sabe.

Lembrete (Aula 9): distância e escala

O KNN (k vizinhos mais próximos) media a semelhança de duas observações pela **distância euclidiana** e padronizava cada coluna antes:

$$d(\mathbf{x}_i, \mathbf{x}_{i'}) = \sqrt{\sum_{j=1}^{p} (x_{ij} - x_{i'j})^2}, \qquad z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \quad \text{(média 0 e desvio padrão 1).}$$

Três imóveis (área, distância, idade), com os desvios padrão do cadastro (41,0 m², 1,62 km e 16,5 anos):

	área	dist	idade	$d(A, \cdot)$, bruta	$d(A, \cdot)$, padronizada
A	120	0,5	20	—	—
B	124	4,5	22	6,0	2,47
C	160	0,5	20	40,0	0,98

Em palavras: sem padronizar, B é o vizinho de A: os 4 km de praia valem tanto quanto 4 m². Padronizado, C é que é parecido com A — 40 m² são menos de um desvio padrão, e 4 km são quase dois e meio. Agrupamento e PCA dependem de distâncias e variâncias: **hoje, tudo padronizado**.

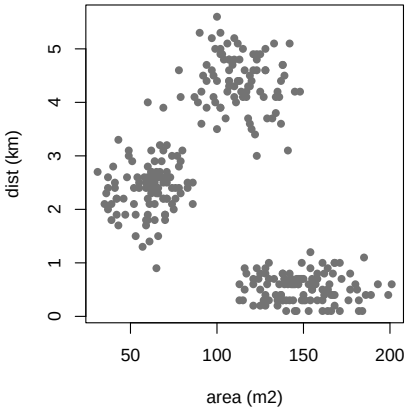
Agrupamento: o K-médias

Você vê grupos?

Duas das seis colunas, sem cor nenhuma — o perfil não está no cadastro:

```
par(mar = c(4,4,1,1), pty = "s")
plot(cad$area, cad$dist, pch = 16,
     col = "gray45", xlab = "area (m2)",
     ylab = "dist (km)")
```

Um grupo é um conjunto de observações parecidas entre si e diferentes das dos outros grupos. No plano, o olho acha três nuvens. Com seis colunas, não há plano para olhar: é preciso um algoritmo — e uma definição precisa de “parecido”.



O que o K-médias procura

Definição

Um **agrupamento** em K grupos $C_1, \ldots, C_K$ põe cada observação em exatamente um grupo. O **K-médias** (*K-means*) procura o agrupamento que minimiza a **soma dos quadrados dentro dos grupos**

$$W = \sum_{k=1}^{K} \sum_{i \in C_k} \|\mathbf{x}_i - \bar{\mathbf{x}}_k\|^2, \qquad \bar{\mathbf{x}}_k = \text{a média (o } \textit{centro}\text{) das observações de } C_k.$$

Em palavras: cada imóvel paga o quadrado da distância até o centro do seu grupo. Grupos bons são compactos: W pequeno. No R, W é o `tot.withinss` do `kmeans()`.

Dois fatos que guiam o resto da aula:

- **Mais grupos sempre baixam W.** Com $K = n$, cada imóvel é o centro de si mesmo e $W = 0$. Então W, sozinho, não escolhe K.
- **Não dá para testar todos os agrupamentos.** Há cerca de $K^n/K!$ jeitos de dividir n observações em K grupos: com $n = 300$ e $K = 3$, mais de 10^{142}. O K-médias busca um bom, passo a passo.

O algoritmo: atribuir e recalcular

```
1.  escolha K e sorteie K observacoes para serem os centros iniciais
2.  repita:
   a.  atribua cada observacao ao centro mais proximo
   b.  recalcule cada centro como a media das observacoes do seu grupo
3.  pare quando nenhuma observacao mudar de grupo
4.  repita 1 a 3 com varios sorteios (nstart) e fique com o menor W
```

Por que ele para. O passo (a) não aumenta W: cada observação vai para o centro mais perto. O passo (b) também não: a média é o ponto que minimiza a soma dos quadrados das distâncias até as observações do grupo. Como W só desce e o número de agrupamentos é finito, o algoritmo termina.

Onde ele para. Num **ótimo local**: um agrupamento que nenhum passo melhora, mas que não é necessariamente o de menor W. O resultado depende do sorteio inicial — por isso o passo 4. No R: `kmeans(Z, centers = K, nstart = 25)` roda 25 começos e devolve o de menor W.

Na mão: sete áreas, dois começos

Áreas (m^2): 50, 60, 70, 140, 150, 160 e 250. Uma coluna só, então a distância é a diferença. $K = 3$.

começo	passo	grupos (atribuição ao centro mais perto)	centros (as médias)
ruim: 50, 60, 70	1	$\{50\}\ \{60\}\ \{70, 140, 150, 160, 250\}$	50; 60; 154
	2	$\{50\}\ \{60, 70\}\ \{140, 150, 160, 250\}$	50; 65; 175
	3	ninguém muda de grupo: para	$W = 0 + 50 + 7\,700 =$ **7 750**
bom: 60, 150, 250	1	$\{50, 60, 70\}\ \{140, 150, 160\}\ \{250\}$	60; 150; 250
	2	ninguém muda de grupo: para	$W = 200 + 200 + 0 =$ **400**

No começo ruim, o passo 2 move o 70 para o centro 60 ($|70 - 60| = 10$, contra $|70 - 154| = 84$); no passo 3, o 140 fica com o 175 (35, contra 75 do 65), e nada mais muda.

Em palavras: os dois começos param, mas o ruim parou num ótimo local quase vinte vezes pior. Daí os vários sorteios. E o 250, sozinho num grupo: é um perfil de imóvel ou um ponto fora da curva? O K-médias não sabe — quem decide é você.

O *K*-médias no R: o perfil que ele não viu

```r
Z  <- scale(cad)                          # padroniza as 6 colunas
set.seed(1)
km <- kmeans(Z, centers = 3, nstart = 25)      # 25 comecos; fica o de menor W
```

```r
table(grupo = km$cluster,
      perfil = perfil)
```

```
#>       perfil
#> grupo orla centro afastado
#>     1  108      0        0
#>     2    2    100        1
#>     3    0      0       89
```

```r
round(aggregate(cad, list(grupo = km$cluster),
                mean), 1)           # os centros
```

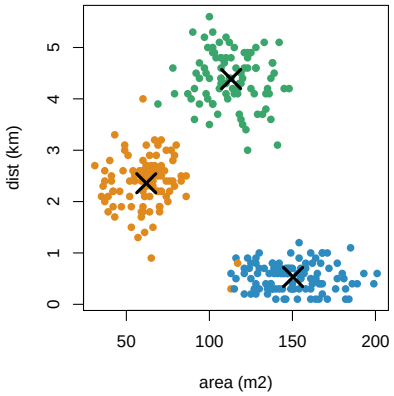
```
#>   grupo  area quartos banheiros vagas dist idade
#> 1     1 150.4     3.6       2.5   2.0  0.5  21.8
#> 2     2  62.0     1.7       1.2   0.7  2.4  44.3
#> 3     3 113.1     2.8       1.8   1.4  4.4   8.4
```

Leia a saída: sem nunca ver o perfil (ele só entra na tabela, para conferir), o *K*-médias pôs **297 dos 300** imóveis com os do seu perfil. Os centros, nas unidades originais, dizem quem é quem: o grupo 1 tem 150 m² a 0,5 km da praia (a orla); o 2, 62 m² e 44 anos (o centro antigo); o 3, 4,4 km e 8 anos (o afastado novo). O *nome* de cada grupo é trabalho seu, não do algoritmo.

Os grupos no plano área × distância

O *K*-médias usou as seis colunas; a figura mostra duas, com a cor do grupo e o centro de cada um (X):

```
cor_g <- c(cazul, claranja, cverde)
par(mar = c(4,4,1,1), pty = "s")
plot(cad$area, cad$dist, pch = 16,
     col = cor_g[km$cluster],
     xlab = "area (m2)", ylab = "dist (km)")
cen <- aggregate(cad[, c("area", "dist")],
                 list(km$cluster), mean)
points(cen$area, cen$dist, pch = 4,
       cex = 2.5, lwd = 3)
```



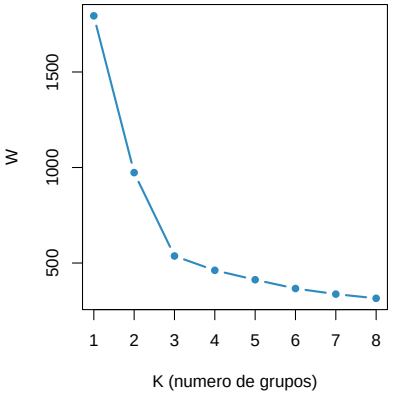
Leia a figura: as três nuvens da página anterior viraram três grupos. Os 3 imóveis postos com os de outro perfil estão nas bordas das nuvens — num agrupamento, a fronteira é sempre a parte duvidosa. A próxima seção mede essa dúvida.

Quantos grupos?

O cotovelo: quando um grupo a mais deixa de valer

W para $K = 1$ a 8, cada um com 25 começos:

```
W <- sapply(1:8, function(k) { set.seed(1)
  kmeans(Z, centers = k,
         nstart = 25)$tot.withinss })
par(mar = c(4,4,1,1), pty = "s")
plot(1:8, W, type = "b", pch = 16,
     col = cazul, lwd = 2,
     xlab = "K (numero de grupos)", ylab = "W")
```



Leia a figura: W cai 46% de 1 para 2 grupos e 45% de 2 para 3. Depois, só 14%, 11%, 11%. O **cotovelo** está em $K = 3$: daí em diante, cada grupo novo só fatia um grupo que já era bom.

Honestidade: o cotovelo é visual, e em muitos bancos a curva desce suave, sem dobra nenhuma. Falta um critério que não dependa do olho: a silhueta.

A silhueta: cada observação está no grupo certo?

Definição

Para a observação i, no grupo C: $a(i)$ é a distância média de i às outras observações de C; $b(i)$ é a menor, entre os outros grupos, das distâncias médias de i às observações de cada um. A **silhueta** de i é

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i),\, b(i)\}} \;\in\; [-1,\, 1].$$

Se i está sozinho no grupo, $a(i)$ não existe e, por convenção, $s(i) = 0$.

Em palavras: s perto de 1 — i está bem mais perto do seu grupo que do vizinho; perto de 0 — está na fronteira; negativa — estaria melhor no grupo vizinho. A **silhueta média** de todas as observações julga o agrupamento inteiro: escolha o K que a maximiza.

Exemplo

Nas sete áreas, com os grupos $\{50, 60, 70\}$, $\{140, 150, 160\}$ e $\{250\}$, a silhueta do 70: $a = (20 + 10)/2 = 15$; até o grupo do meio, a distância média é $(70 + 80 + 90)/3 = 80$, e até o 250, 180; então $b = 80$ e $s = (80 - 15)/80 \approx \mathbf{0{,}81}$ — bem alocado.

A silhueta no R: seis linhas, sem pacote

```r
silhueta <- function(g, D) {            # g: os grupos; D: as distancias (dist)
  D <- as.matrix(D); n <- length(g)
  sapply(1:n, function(i) {
    a <- mean(D[i, g == g[i] & seq_len(n) != i])          # o proprio grupo
    b <- min(tapply(D[i, g != g[i]], g[g != g[i]], mean))  # o grupo vizinho
    if (is.nan(a)) 0 else (b - a) / max(a, b) })           # sozinho: 0
}
D <- dist(Z)                                    # distancias padronizadas
S <- sapply(2:8, function(k) { set.seed(1)
  mean(silhueta(kmeans(Z, centers = k, nstart = 25)$cluster, D)) })
round(rbind(K = 2:8, silhueta = S), 2)

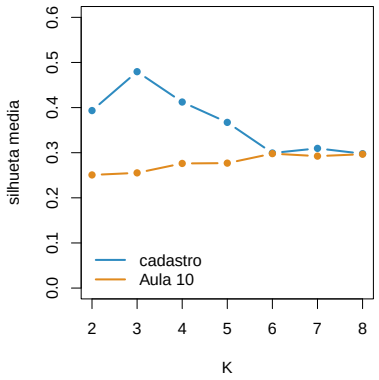
#>           [,1] [,2] [,3] [,4] [,5] [,6] [,7]
#> K         2.00 3.00 4.00 5.00  6.0 7.00  8.0
#> silhueta 0.39 0.48 0.41 0.37  0.3 0.31  0.3
```

Leia a saída: a silhueta média é máxima em $K = 3$ (0,48) — o mesmo K do cotovelo, agora sem depender do olho. Os 3 imóveis postos com os de outro perfil têm silhueta 0,13, 0,07 e 0,00, contra uma mediana de 0,50: são de fronteira, e a silhueta os aponta. (A `silhouette()` do pacote `cluster` faz a mesma conta.)

O K-médias sempre devolve K grupos — mesmo onde não há

Os 300 imóveis da Aula 10 tiveram área, praia e idade sorteadas por igual, sem perfil nenhum. O K-médias divide também esses:

```
Zu <- scale(imov)            # imoveis da Aula 10
Su <- sapply(2:8, function(k) { set.seed(1)
  g <- kmeans(Zu, centers = k, nstart = 25)$cluster
  mean(silhueta(g, dist(Zu))) })
par(mar = c(4,4,1,1), pty = "s")
plot(2:8, S, type = "b", pch = 16, lwd = 2,
     col = cazul, ylim = c(0, 0.6),
     xlab = "K", ylab = "silhueta media")
lines(2:8, Su, type = "b", pch = 16, lwd = 2,
      col = claranja)
legend("bottomleft", c("cadastro", "Aula 10"),
       col = c(cazul, claranja), lwd = 2, bty = "n")
```



Leia a figura: no cadastro (azul), um pico claro em $K = 3$. Nos imóveis sem grupos (laranja), a curva fica entre 0,25 e 0,30, sem pico: nenhum K se destaca. O algoritmo dividiu do mesmo jeito — ele sempre divide. A silhueta não prova que os grupos existem, mas mostra quando não há o que separar.

Agrupamento hierárquico

Agrupamento hierárquico: juntar os mais próximos

O K-médias pede o K antes e sorteia o começo. O **agrupamento hierárquico aglomerativo** não pede nenhum dos dois:

```
1.  comece com n grupos, um por observacao
2.  repita ate sobrar um grupo so:
   a.  junte os dois grupos mais proximos
   b.  anote a altura:  a distancia em que eles se juntaram
3.  desenhe as juncoes (o dendrograma) e corte na altura que der K grupos
```

A distância entre dois *grupos* G e H é a **ligação** (*linkage*), calculada sobre as distâncias $d(i, j)$, com $i \in G$ e $j \in H$:

- **completa**: a maior $d(i, j)$ — os grupos se juntam quando *todos* estão perto (o padrão do `hclust()`);
- **média**: a média das $d(i, j)$;
- **simples**: a menor $d(i, j)$ — basta *um* par perto.

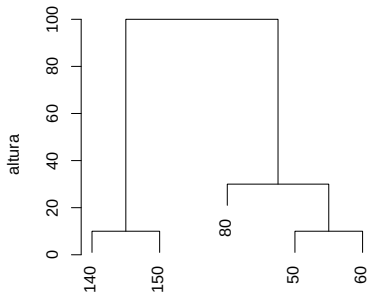
Em palavras: o **dendrograma** guarda todos os K de uma vez: um corte baixo dá muitos grupos, um alto, poucos. E não há sorteio: o resultado é sempre o mesmo.

Na mão: cinco áreas, ligação completa

Áreas (m^2): 50, 60, 80, 140 e 150.

1. As distâncias menores são $d(50, 60) = 10$ e $d(140, 150) = 10$: os dois pares se juntam na altura **10**.
2. O 80 até $\{50, 60\}$: a maior distância é $\max(30, 20) = 30$; até $\{140, 150\}$, $\max(60, 70) = 70$. Ele entra no primeiro grupo na altura **30**.
3. Os dois grupos que sobram: a maior distância é $150 - 50 = \mathbf{100}$.

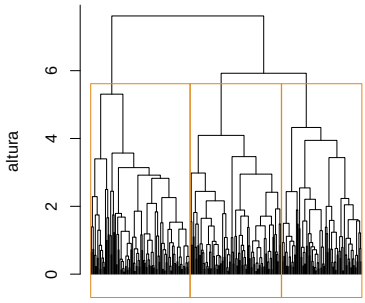
```
a5 <- c(50, 60, 80, 140, 150)
h5 <- hclust(dist(a5), method = "complete")
par(mar = c(1,4,1,1), pty = "s")
plot(h5, labels = a5, main = "", sub = "",
     xlab = "", ylab = "altura")
```



Cortando na altura 50, dois grupos: $\{50, 60, 80\}$ e $\{140, 150\}$.

O dendrograma dos 300 imóveis

```
hc <- hclust(D, method = "complete")
par(mar = c(1,4,1,1), pty = "s")
plot(hc, labels = FALSE, hang = -1, main = "",
     sub = "", xlab = "", ylab = "altura")
rect.hclust(hc, k = 3, border = claranja)
```




```
table(grupo = cutree(hc, k = 3), perfil = perfil)

#>       perfil
#> grupo orla centro afastado
#>     1    0      0       89
#>     2    0    100        1
#>     3  110      0        0
```

Leia: o corte em 3 grupos (os retângulos) põe 299 dos 300 imóveis com os do seu perfil; a ligação média põe 300, e o *K*-médias pôs 297. Já a ligação **simples**, no mesmo corte, faz grupos de 189, 110 e 1 imóveis: junta o centro e o afastado e deixa um imóvel sozinho. Basta um par de vizinhos perto para unir dois grupos, e os pares formam correntes — o **encadeamento**.

Componentes principais (PCA)

Seis colunas: quantas informações?

```
round(cor(cad), 2)


#>            area quartos banheiros vagas  dist idade
#> area       1.00    0.85      0.78  0.76 -0.39 -0.55
#> quartos    0.85    1.00      0.65  0.64 -0.36 -0.47
#> banheiros  0.78    0.65      1.00  0.63 -0.39 -0.38
#> vagas      0.76    0.64      0.63  1.00 -0.34 -0.43
#> dist      -0.39   -0.36     -0.39 -0.34  1.00 -0.29
#> idade     -0.55   -0.47     -0.38 -0.43 -0.29  1.00
```

Leia a saída: área, quartos, banheiros e vagas têm correlações de 0,63 a 0,85: quatro colunas que medem quase a mesma coisa, o **tamanho**. A distância e a idade correlacionam menos com elas (e entre si, −0,29).

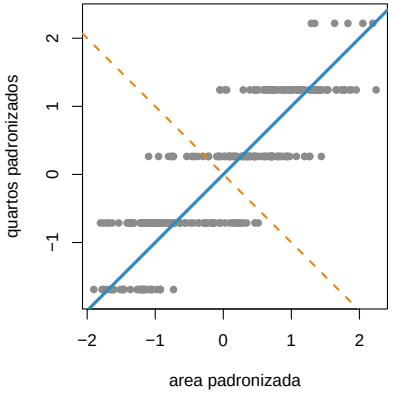
Talvez as seis colunas guardem só duas ou três informações. A **análise de componentes principais** (PCA) acha essas informações: **poucas combinações das colunas que guardam quase toda a variação**. Como o agrupamento, ela não olha o perfil — nem nenhum Y.

A direção de maior variância

Duas colunas padronizadas, área e quartos ($r = 0{,}85$):

```
za <- as.vector(scale(cad$area))
zq <- as.vector(scale(cad$quartos))
par(mar = c(4,4,1,1), pty = "s")
plot(za, zq, pch = 16, col = "gray55", asp = 1,
     xlab = "area padronizada",
     ylab = "quartos padronizados")
abline(0, 1, col = cazul, lwd = 3)        # PC1
abline(0, -1, col = claranja, lwd = 2,
       lty = 2)                           # PC2
```

Quartos é um número inteiro: os pontos formam faixas.



Leia a figura: os pontos se espalham ao longo da diagonal (azul). Projetados nela, os 300 imóveis têm variância 1,85; na perpendicular (laranja), só 0,15. A diagonal guarda 93% da variação das duas colunas: dá para trocar duas colunas por uma, o tamanho, perdendo 7%.

Componentes principais: a definição

Definição

A **primeira componente principal** das colunas padronizadas $z_1, \ldots, z_p$ é a combinação $\mathrm{PC}1 = \phi_{11} z_1 + \phi_{21} z_2 + \cdots + \phi_{p1} z_p$, com $\sum_j \phi_{j1}^2 = 1$, de **maior variância**. A **segunda**, $\mathrm{PC}2$, é a de maior variância entre as que não têm correlação com a PC1 — e assim até a p-ésima. Os **pesos** ϕ (*loadings*) são os **autovetores** da matriz de correlação; as variâncias das componentes são os **autovalores** $\lambda_1 \geq \cdots \geq \lambda_p$, que somam p.

Em palavras: a PC1 é a régua que mais espalha as observações; a PC2, a que mais espalha no que sobrou. A componente m explica a fração λ_m / p da variação total. O valor de cada observação numa componente é o seu **escore**.

```
1. padronize as colunas (media 0 e desvio padrao 1)
2. calcule a matriz de correlacao (p x p)
3. ache os autovetores e os autovalores, em ordem do maior autovalor
4. escore de cada observacao na componente m:  a soma de phi_jm * z_j
5. fique com as primeiras componentes, que guardam a maior parte da variancia
```

Na mão: duas colunas com correlação r

Com duas colunas padronizadas, a matriz de correlação e os seus autovetores saem de cabeça:

$$\begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix} \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} = (1+r) \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}, \qquad \begin{pmatrix} 1 & r \\ r & 1 \end{pmatrix} \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix} = (1-r) \begin{pmatrix} -1/\sqrt{2} \\ 1/\sqrt{2} \end{pmatrix}.$$

Então, se $r > 0$: $\mathrm{PC1} = (z_1 + z_2)/\sqrt{2}$, com variância $\lambda_1 = 1 + r$, e $\mathrm{PC2} = (z_2 - z_1)/\sqrt{2}$, com $\lambda_2 = 1 - r$. A PC1 explica $(1+r)/2$ da variação.

Exemplo

Área e quartos, $r = 0{,}85$: $\lambda_1 = 1{,}85$, e a PC1 explica 93% — a diagonal do slide anterior. Um imóvel de 160 m² e 4 quartos: $z_{\text{área}} = (160 - 109{,}0)/41{,}0 = 1{,}25$ e $z_{\text{quartos}} = (4 - 2{,}73)/1{,}02 = 1{,}24$; o escore na PC1 é $(1{,}25 + 1{,}24)/\sqrt{2} = \mathbf{1{,}76}$: 1,76 desvios acima da média, na régua do tamanho.

Em palavras: com duas colunas, a PCA é a soma (PC1) e a diferença (PC2). Quanto maior a correlação, mais a soma guarda.

A PCA no R: seis colunas, duas réguas

O `prcomp()` padroniza (`scale. = TRUE`) e acha as componentes; o `summary()` dá as frações da variação, e `rotation`, os pesos:

```
pca <- prcomp(cad, scale. = TRUE)
ve  <- summary(pca)$importance[2, ]       # fracoes
round(rbind(fracao = ve, acumulada = cumsum(ve)), 2)
round(pca$rotation[, 1:2], 2)

#>             PC1  PC2  PC3  PC4  PC5  PC6
#> fracao     0.61 0.22 0.06 0.06 0.04 0.02
#> acumulada 0.61 0.82 0.88 0.94 0.98 1.00
#>              PC1   PC2
#> area        0.50  0.02
#> quartos     0.46  0.00
#> banheiros   0.44 -0.09
#> vagas       0.44 -0.01
#> dist       -0.23  0.74
#> idade      -0.30 -0.66
```

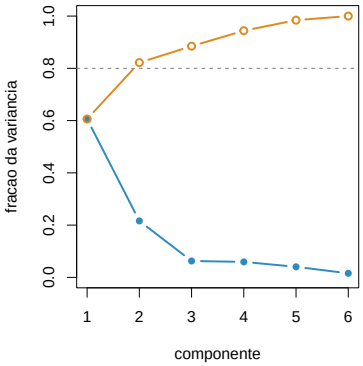
Leia a saída: a PC1 guarda 61% da variação; a PC2, 22% — juntas, 82%. Cada uma se lê pelos pesos:

- na **PC1**, as quatro colunas de tamanho pesam de 0,44 a 0,50, com o mesmo sinal; distância e idade pesam menos, com o sinal contrário: a PC1 é o **tamanho**;
- na **PC2**, quase só a distância e a idade, com sinais opostos (0,74 e 0,66, em módulo): longe da praia e novo, contra perto ou antigo — o **lugar**.

O sinal de cada componente é arbitrário: trocar todos os sinais de uma coluna de pesos dá a mesma componente. Outra máquina pode mostrar os sinais trocados.

Quantas componentes?

```
ve <- pca$sdev^2 / sum(pca$sdev^2)   # fracoes
par(mar = c(4,4,1,1), pty = "s")
plot(1:6, ve, type = "b", pch = 16, lwd = 2,
     col = cazul, ylim = c(0, 1),
     xlab = "componente",
     ylab = "fracao da variancia")
lines(1:6, cumsum(ve), type = "b", lwd = 2,
      col = claranja)                # acumulada
abline(h = 0.8, lty = 2, col = "gray50")
```

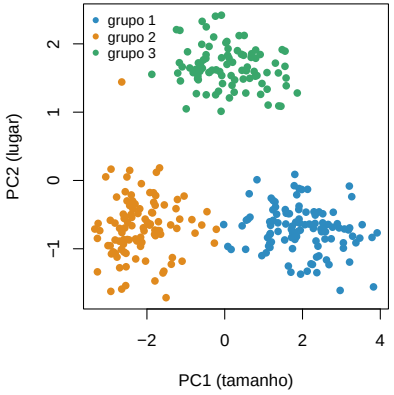


Leia a figura: três regras práticas, e todas apontam duas componentes. O **cotovelo**: depois da PC2, cada componente guarda menos de 7%. O **autovalor maior que 1** (a componente guarda mais que uma coluna original): $\lambda = 3{,}64$ e $1{,}30$, depois $0{,}38$. E os **80% acumulados** (o tracejado). Seis colunas, duas informações: o tamanho e o lugar.

Os grupos no plano das duas componentes

Cada imóvel nas duas réguas da PCA (os escores, em `pca$x`), com a cor do grupo do *K*-médias, a mesma do slide 10:

```
cor_g <- c(cazul, claranja, cverde)
par(mar = c(4,4,1,1), pty = "s")
plot(pca$x[, 1], pca$x[, 2], pch = 16,
     col = cor_g[km$cluster],
     xlab = "PC1 (tamanho)",
     ylab = "PC2 (lugar)")
legend("topleft", paste("grupo", 1:3),
       col = cor_g, pch = 16, bty = "n",
       cex = 0.8)
```



Leia a figura: os três grupos ocupam três regiões do plano. A orla e o centro ficam nas pontas da PC1 (grandes e pequenos); o afastado se separa deles pela PC2. A PCA mostra em duas dimensões o que o *K*-médias achou em seis — e, rodado só nas duas componentes, ele põe 297 dos 300 com os do seu perfil, como nas seis colunas.

Cuidados ao usar

- **Padronize.** Sem `scale. = TRUE`, a PCA olha a variância bruta, e mandam as colunas de unidade grande: a área (variância de 1 679 m^4) e a idade (271 $anos^2$). A PC1 sobe para 91% e é quase só a área (peso 0,97); quartos, banheiros e vagas pesam 0,02 ou menos. O mesmo vale para o *K*-médias (o lembrete do começo).
- **Nenhum dos dois olha o *Y*.** A direção de maior variância das colunas pode não ter nada a ver com a resposta, e um grupo bem separado pode ter o mesmo *Y* que o vizinho. Para prever, componentes e grupos são preparação: viram preditores (ou recortes) e passam pela validação cruzada, como qualquer outro.
- **Nome é interpretação.** "Tamanho", "lugar", "orla": os nomes saem dos pesos e dos centros, e quem os dá é você. O sinal de uma componente e o número de um grupo são arbitrários.
- **Grupo é resumo, não verdade.** Confira com a silhueta, com outros sorteios, com outro método (o hierárquico) e com quem conhece o problema. No cadastro, sabíamos a verdade; no seu banco, não.

Exercícios e trabalho

Exercícios — cálculo

Exercício

Áreas 50, 60, 70, 140, 150, 160 e 250 m^2. Rode o K-médias com $K = 2$ a partir dos centros 50 e 60 até parar. Qual o W final? Compare com o de $K = 3$ e diga por que W sozinho não escolhe K.

Exercício

Com os grupos $\{50, 60, 70\}$, $\{140, 150, 160\}$ e $\{250\}$, calcule a silhueta do 160. Que grupo é o vizinho dele?

Exercício

Áreas 50, 60, 80, 140 e 150: refaça as junções com a ligação simples e com a média. Em que altura o 80 entra? E a última junção?

Exercício

Duas colunas padronizadas têm correlação 0,6. Quanto da variância a PC1 guarda? Escreva a PC1 e calcule o escore de uma observação com $z = (2,\ 1)$.

Exercícios — conceituais

Exercício (Escala)

Sem padronizar, que coluna manda no K-médias do cadastro? E se a distância estivesse em metros?

Exercício (Grupos que não existem)

O K-médias devolveu 3 grupos nos imóveis da Aula 10. Como saber se os grupos de um banco existem?

Exercício (Simples $\times$ completa)

Por que a ligação simples juntou o centro e o afastado, e a completa não?

Exercício (A PC1 e o preço)

A PC1 guarda 61% da variação das características. Então ela é o melhor preditor do preço? O que a PCA não olha?

Exercício (Grupos e a sua pergunta)

Dê duas maneiras de usar um agrupamento numa pergunta supervisionada.

Laboratório — no seu banco de dados

As colunas numéricas da **ficha da sua pergunta** (Entrega 1), sem a resposta; a `silhueta( )` é a do slide 13:

```r
d <- na.omit(data.frame(y = dados$y, x1 = dados$x1, x2 = dados$x2, x3 = dados$x3, x4 = dados$x4))
# banco grande? a silhueta usa uma matriz n x n: trabalhe numa amostra, d <- d[sample(nrow(d), 2000), ]
X <- d[, -1]                                  # so os preditores: a resposta fica de fora
pca <- prcomp(X, scale. = TRUE)
summary(pca); round(pca$rotation[, 1:2], 2)   # variancia explicada e pesos
Z <- scale(X); D <- dist(Z)
S <- sapply(2:8, function(k) { set.seed(1)
  mean(silhueta(kmeans(Z, centers = k, nstart = 25)$cluster, D)) })
K <- (2:8)[which.max(S)]; set.seed(1); km <- kmeans(Z, centers = K, nstart = 25)
aggregate(X, list(grupo = km$cluster), mean)  # os grupos nas unidades originais
par(mfrow = c(1, 2), pty = "s")
plot(pca$x[, 1:2], col = km$cluster, pch = 16)   # os grupos no plano PC1 x PC2
boxplot(d$y ~ km$cluster, xlab = "grupo", ylab = "y")   # e a resposta em cada grupo
```

Entregar (código em `estrutura/codigo/`, registro em `consolidados/`): a variância explicada e um nome para a PC1 e a PC2, tirado dos pesos; a silhueta por K e o K escolhido (ou a conclusão de que não há grupos); os centros nas unidades originais, com um nome para cada grupo; as duas figuras; e **o que isso muda para a sua pergunta**: a resposta muda de um grupo para outro? O grupo vira preditor?

Resumo

- **Não supervisionado:** sem resposta, procura-se estrutura — **grupos** de observações parecidas e **direções** que resumem as colunas. Padronize antes: distância e variância dependem da escala.
- ***K*-médias:** atribui cada observação ao centro mais próximo e recalcula os centros até parar, num ótimo local (daí os vários começos). O *K* sai da **silhueta** e do cotovelo — e o algoritmo sempre devolve *K* grupos, mesmo onde não há.
- **Hierárquico:** junta os dois grupos mais próximos, um passo por vez; o **dendrograma** guarda todos os *K*, e a ligação (completa, média ou simples) muda o resultado.
- **PCA:** combinações das colunas, sem correlação entre si, em ordem de variância — os autovetores da matriz de correlação. Poucas componentes resumem muitas colunas; o nome vem dos pesos, e nenhuma delas olha o *Y*.

Próximas aulas: os trabalhos. Cada grupo leva o kit do semestre — da pergunta à validação — para o seu banco; agrupamento e PCA entram como exploração.